

推荐PM手把手入门第7讲：召回初探，协同过滤

其实就是"物以类聚"

👉 嗨，我是  大厂策略产品搬砖狗，又见面了。

最近在写这个专栏的时候，我在想用什么类比来给大家介绍协同过滤，最后我觉得这么描述会比较清晰：**协同过滤这个听起来很技术的东西，本质上就是我们日常生活中最朴素的一个道理——"物以类聚，人以群分"。**

今天这篇，我想用最产品化的视角，带你拆解协同过滤到底在干什么，以及作为PM，我们怎么把它真正用起来。

你从这篇文章能获得什么？



协同过滤整体介绍

一、先说说我为什么要写召回

在刚开始工作的时候，我自己对推荐系统的认知其实也挺模糊的。最开始接触的是"召回-粗排-精排-重排"这套链路，当时脑子里想的是：召回不就是把内容捞出来吗？有什么好讲的？

真正开始负责召回策略之后才发现：**召回才是整个推荐系统的地基。**

你精排做得再牛，模型再复杂，如果召回阶段就把好内容漏掉了，后面再怎么排也排不出花来。而且很现实的一点是，召回的效率直接决定了整个系统的成本——你不可能把全库内容都扔给精排，那计算量会爆炸。

所以召回的核心任务就两个：

1. 把可能让用户感兴趣的内容找出来
2. 在保证召回质量的前提下，控制召回量级

而协同过滤，就是召回里最经典、最基础、也是最容易理解的一种策略。

二、协同过滤到底在干什么？

我先说结论：**协同过滤就是通过"找相似"来做推荐。**

具体来说分两种：

- **User-based(基于用户)**：找到和你相似的用户，把他们喜欢的内容推给你
- **Item-based(基于物品)**：找到和你喜欢过的内容相似的其他内容，推给你

听起来很抽象对吧？我举个例子你就懂了。

场景一：User-based

假设你是个喜欢看美食视频的用户，平台发现还有一群用户也喜欢看美食，而且他们除了美食，还经常看旅行vlog。那平台就会想：你可能也会喜欢旅行vlog，于是把这类内容推给你。

这就是基于用户的协同过滤：找到兴趣相似的人，把他们的偏好迁移到你身上。

场景二：Item-based

假设你最近看了一个讲咖啡拉花的视频，平台发现很多看过这个视频的用户，也看了另一个讲手冲咖啡的视频。那平台就会想：这两个视频可能内容相关，于是把手冲咖啡那条推给你。

这就是基于物品的协同过滤：找到内容之间的关联，通过"看了A的人也看了B"来做推荐。

三、两种协同过滤怎么选？

这是我刚接手召回时最困惑的问题。技术同学跟我说"我们可以做User-based，也可以做Item-based"，我当时脑子里就一个想法：**那到底该用哪个？**

后来我发现，选择哪种，核心要看你的**业务场景**。

User-based 适合什么场景？

适合**用户行为稳定、物品数量远大于用户数量**的场景。

举个例子，电商平台的商品可能有几百万SKU，但活跃用户可能只有几十万。这种情况下，计算用户之间的相似度比计算物品之间的相似度要高效得多。

而且User-based有个天然优势：**能发现跨品类的兴趣迁移**。比如喜欢跑步的人可能也喜欢健康饮食，这种关联通过用户行为就能挖出来。

但问题是：**实时性差**。因为用户的兴趣会变化，你需要频繁更新用户相似度矩阵，计算成本很高。

Item-based 适合什么场景？

适合**物品相对稳定、用户数量多且行为碎片化**的场景。

内容平台就是典型案例。小红书上每天有海量用户产生行为，但笔记的内容属性相对稳定。这种情况下，计算物品之间的相似度，然后离线存下来，线上直接查表，效率会高很多。

而且Item-based有个很大的优点：**可解释性强**。你给用户推荐一条内容，可以明确说"因为你看过A，所以推荐B"，这在很多场景下很重要。

但Item-based也有局限：**容易陷入信息茧房**。如果一个用户只看美食，你就只会推美食相关的，很难帮用户拓展兴趣边界。

四、协同过滤背后的数学逻辑(但我不讲公式)

虽然我说不讲算法，但作为PM，你得理解协同过滤背后的核心思想，这样才能跟技术同学对齐，也才能知道策略的边界在哪。协同过滤的本质是：**通过历史行为数据，计算相似度，然后基于相似度做预测。**

相似度怎么算？

最常见的方法有几种：

- **余弦相似度**：把用户或物品看成向量，计算夹角
- **皮尔逊相关系数**：考虑用户评分的偏差
- **Jaccard相似度**：适合二值化场景(点击/未点击)

我不展开讲公式，你只需要知道：**这些方法都是在量化"有多像"这件事。**

怎么用相似度做推荐？

以Item-based为例，流程是这样的：

1. 用户A点击了物品X
2. 系统找出和X最相似的N个物品(比如Y、Z)
3. 把Y、Z推给用户A

听起来很简单对吧？但实际落地的时候，有很多细节要抠。

五、作为PM，我们要关注什么？

讲完原理，现在说说实操层面，PM在协同过滤召回里到底要干什么。

1. 定义"相似"

这是最核心的一步。**什么叫相似？是内容标签相似，还是用户行为相似？**

举个例子，两条美食笔记，一条讲川菜，一条讲粤菜，算相似吗？

- 如果按大类(美食)，它们相似
- 如果按菜系，它们不相似

这个没有标准答案，取决于你的业务目标。如果你想让用户深度沉浸在某个细分领域，那就按细粒度算相似；如果你想帮用户拓展兴趣，那就按粗粒度算。

我的做法是：**先定义业务上的"相似"，再倒推技术实现。**

2. 选择行为信号

协同过滤依赖用户行为，但不是所有行为都应该用。

常见的行为信号：

- 点击/曝光
- 点赞/收藏
- 评论/分享
- 完播率/停留时长

你要根据业务场景决定**哪些信号权重更高**。

举个例子，如果你做的是短视频平台，完播率可能比点赞更重要，因为完播意味着用户真的看完了，而点赞可能只是随手点的。但如果你做的是图文平台，点赞和收藏可能比停留时长更有效，因为图文的停留时长本身就不长。

3. 冷启动问题

这是协同过滤最大的痛点：**新用户没有历史行为，新内容没有被消费过，怎么办？**

常规的解决方案是：

- **新用户**：先用规则召回(比如热门内容)或者基于用户画像的召回，等用户有了一定行为后再启用协同过滤
- **新内容**：先给新内容一定的冷启动流量，等它积累了足够的行为数据，再纳入协同过滤体系

这部分我会在后面的文章里详细讲，这里先埋个坑。

4. 数据稀疏性

协同过滤依赖的是"共现"关系，但很多时候，用户和内容之间的交互是非常稀疏的。

举个例子，平台有100万用户，1000万内容，但每个用户平均只消费过100条内容。这种情况下，用户-物品矩阵里99.999%的格子都是空的。

稀疏性会导致相似度计算不准。

解决办法有几种：

- 降维(比如用矩阵分解)
- 引入更多特征(比如内容标签、用户画像)
- 结合其他召回策略

这也是为什么实际业务中，我们不会只用协同过滤，而是会做**多路召回**。

六、一个真实的思考：协同过滤的天花板在哪？

写到这里，我想聊点更深层的东西。

协同过滤很好用，但它有个天然的局限：**它只能基于过去的行为做推荐，无法预测用户未来的兴趣变化。**

举个例子，一个用户之前一直看美食内容，但最近他开始健身了，兴趣可能从"怎么吃得好"变成了"怎么吃得健康"。协同过滤很难捕捉到这种转变，除非用户已经产生了足够多的健身相关行为。

这也是为什么现在很多平台会引入**深度学习模型**，因为深度学习可以学习到更复杂的特征组合，甚至能做一定程度的"预测"。


但这不代表协同过滤就没用了。恰恰相反，**协同过滤依然是召回里最稳定、最可解释、最容易落地的策略之一。**

我们要做的，是在理解它的边界的基础上，把它和其他策略组合起来用。

七、画个图帮你理解

我画了两张图，帮你直观理解User-based和Item-based的区别。


User-based协同过滤



User-based介绍

这张图展示的是：通过找到相似用户，把他们的偏好迁移到目标用户身上。

Item-based协同过滤



Item-based介绍

这张图展示的是：通过找到相似内容，把用户喜欢过的内容的"邻居"推给用户。

八、写在最后

这篇文章写得比较长，因为协同过滤是召回里最基础的策略，我想把它讲透。

如果你能理解"物以类聚"这四个字，你就已经理解了协同过滤80%的核心思想。剩下的20%，是怎么把它落地，怎么和业务结合，怎么在实际场景中调优。

下一篇，我会讲**向量召回**，那是一个更现代化、更强大的召回方式。但相信我，协同过滤依然值得你花时间去理解，因为很多向量召回的思想，本质上也是从协同过滤演化来的。

如果你对这篇有任何想法，或者想听我讲什么，欢迎留言。

我们下期见。