

分享一下 LLM 与搜索结合的工业界进展

1. 先给结论



大家好，我是  大厂策略产品搬砖狗，在大厂从事搜推策略产品工作 6 年。今天分享下 LLM 和搜索的结合，目前工业界的结合程度已经不是“在搜索框后面接一个 ChatGPT”这么简单。最关键的 PM 认知是：工业界短期内不是让大模型替代整个搜索引擎，而是让 LLM 接管搜索链路里最难结构化的部分：复杂意图理解、检索规划、结果综合、交互解释和任务执行。

落地的四条主线如下，LLM 在搜索里的角色越来越重，对原有产品形态的颠覆性也越来越强。

- 增量改造 — 在原有搜索框架内塞 LLM 当组件
- 重新定义 — 跳出原有框架，让 LLM 改变范式



2. 搜索系统里，LLM 主要插在哪些位置

可以粗略拆成五层：

1. Query 理解/改写
2. 多路召回/检索
3. 排序/重排
4. 答案生成/引用/追问
5. 行动执行

LLM 最先成熟的是两头：前面的 Query 理解，和后面的答案生成。中间的召回、排序仍然大量依赖传统搜索、向量检索、Learning to Rank、质量体系和反作弊系统。换句话说，LLM 搜索不是“不要搜索了”，而是“搜索变成 LLM 的工具”。

3. 工业界进展雷达

方向	成熟度	代表进展
AI 摘要搜索	高	Google AI Overviews、Bing generative search、ChatGPT search
Query fan-out / 多查询规划	高	Google AI Mode 把复杂问题拆成多个子搜索
带引用的答案引擎	高	ChatGPT search、Perplexity、Bing
电商对话式搜索	中高	Amazon Rufus、淘宝长尾 query 改写/AI Search
企业知识库搜索	中高	Vertex AI Search、Microsoft 365 Copilot / Graph grounding
多模态搜索	中	Lens、Search Live、图片/视频理解增强搜索
Agentic search / AI 浏览器	中	ChatGPT Atlas、Perplexity Comet、Edge Copilot Mode
完全端到端 LLM 搜索排序	低到中	多数仍在研究或局部场景验证

4. 哪些能力已经比较成熟

4.1 复杂 Query 理解：最确定的增量

传统搜索很擅长关键词匹配，但对复杂需求会吃力，比如：

- “适合三岁小孩、不过敏、可以在飞机上玩的安静玩具”
- “预算 8000，适合剪视频和写代码的轻薄本”
- “我下周去京都，想避开人多但又能看枫叶的路线”

LLM 的价值是把一句自然语言拆成**约束、偏好、场景和隐含目标**。Google AI Mode 官方提到的 query fan-out，本质上就是让模型把一个复杂问题拆成多个相关搜索，再综合结果。对 PM 来说，这一层最值得先做，因为它不一定改变最终排序系统，却能显著提升长尾 query、口语化 query 和探索型 query 的可用性。

4.2 答案综合：搜索结果页正在从“链接列表”变成“答案页”

Google AI Overviews、Bing generative search、ChatGPT search 都说明一个趋势：**用户不总是想点十个链接，有些问题希望直接得到结构化答案**。这类能力适合：

- 事实型问题：时间、地点、定义、规则。
- 比较型问题：A 和 B 的区别。
- 攻略型问题：路线、步骤、清单。
- 研究型问题：把多来源信息整理成摘要。

但它必须绑定来源。ChatGPT search、Perplexity、Google AI Overviews 都把“引用/链接”作为核心产品能力，因为搜索场景不能只给一个流畅答案，还要能回到证据。

4.3 垂直搜索：电商和企业知识库更容易落地

通用 Web 搜索很难，因为网页质量、时效性、版权、广告、垃圾内容都很复杂。相比之下，垂直场景更适合 LLM 先落地。

- 电商里，Amazon Rufus 把搜索框变成购物助理，训练数据包括商品目录、评论、问答和 Web 信息。淘宝侧也有长尾 query 改写、AI Search 插件等论文和部署披露，核心都是让用户用自然语言描述需求，再把需求翻译成商品检索和排序能理解的表达。
- 企业知识库里，LLM + Search 更像 RAG：先从文档、邮件、会议、工单、Wiki 里找证据，再生成答案。Google Vertex AI Search、Microsoft Copilot 的 grounding 都是这个方向。

4.4 搜索评估：LLM 开始当“标注员”和“裁判”

搜索质量过去依赖人工相关性标注、点击模型、A/B 实验。现在 LLM 可以辅助做：

- Query 意图分类。
- 文档相关性判断。
- 摘要是否被来源支持。
- 答案是否遗漏关键约束。
- 搜索结果多样性和覆盖度评估。

Microsoft Research 在 SIGIR 相关工作里讨论过 LLM 预测搜索者偏好的能力。这个方向很适合内部提效，但 PM 要注意：LLM 评估不能替代真实用户反馈，只能作为更便宜、更快的中间信号。

4.5 Agentic Search：方向很大，但还没完全成熟

AI 浏览器和网页 Agent 的出现，说明搜索正在往下一步走：

- 过去：搜“东京酒店推荐”。
- 现在：总结酒店、比较价格、看评论。
- 未来：根据预算和行程筛选，打开网站，填表，等用户确认后预订。

OpenAI 的 ChatGPT agent/Atlas、Perplexity Comet、Edge Copilot Mode 都在把“搜索”变成“[浏览器里的任务助理](#)”。但这里的风险也更高：网页权限、支付、隐私、错误操作、提示注入，都会比普通搜索复杂很多。

5. 现在的能力边界

1. **第一，LLM 仍然会错。** Google AI Overviews 早期出现过不准确和不有用的回答，Google 后续也公开说明做了多项技术改进。搜索场景里，错答案比“没搜到”更危险，因为它看起来更像结论。
2. **第二，引用不等于可信。** 模型可以引用低质量页面，也可能把来源里的局部内容综合错。PM 不能只看“有没有引用”，还要看来源质量、证据覆盖、答案和证据的一致性。
3. **第三，时效性仍然依赖检索。** LLM 本体不是实时数据库，新闻、价格、库存、政策、比赛、天气这类问题，必须依赖搜索/数据库/API。
4. **第四，成本和延迟仍然重要。** 搜索是高频低延迟产品，不可能每个 query 都跑深度推理。工业界更常见的做法是：简单 query 走传统搜索，复杂 query 才触发 LLM 搜索或 AI Overview。
5. **第五，商业生态会被重构。** AI 答案减少点击，影响 SEO、内容生产者、广告位和流量分发。所以 Google、Perplexity、OpenAI 都在处理来源展示、出版商合作、广告和版权问题。

6. PM 该怎么听懂技术同学的说法

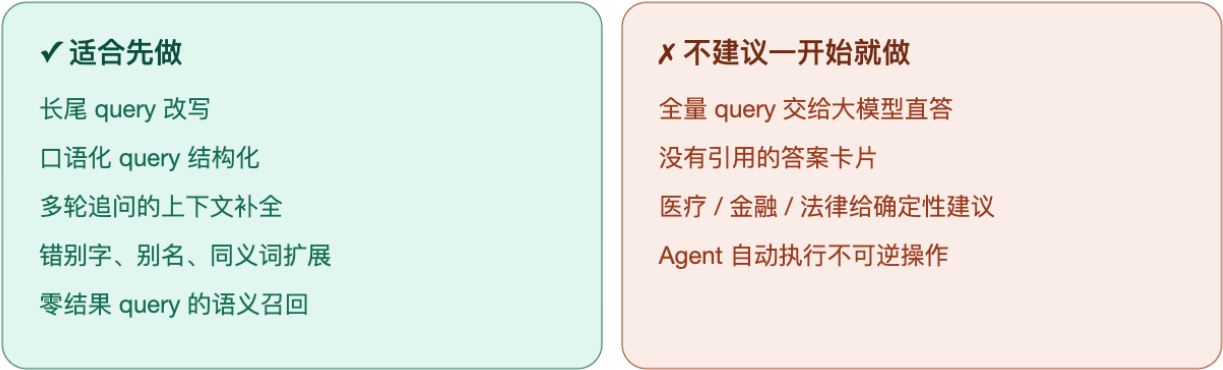
当技术同学说“我们要做 AI Search”，PM 最好想清楚五个问题：

1. **LLM 替换的是哪一层？** Query 改写、召回、重排、摘要，还是 Agent 执行？
2. **结果是否有可追溯来源？** 来源来自 Web、商品库、知识库，还是模型记忆？
3. **哪些 query 触发 LLM？** 全量触发还是只覆盖复杂 query？
4. **线上指标看什么？** CTR、满意度、转化、零结果率、追问率、人工转接率，还是答案采纳率？
5. **出错时怎么兜底？** 返回链接、澄清问题、拒答、降级传统搜索，还是人工审核？

这几个问题比“用哪个模型”更重要。

7. 对搜索 PM 的落地建议

7.1 优先级 1：先做 Query 理解和改写



query 理解相关建议

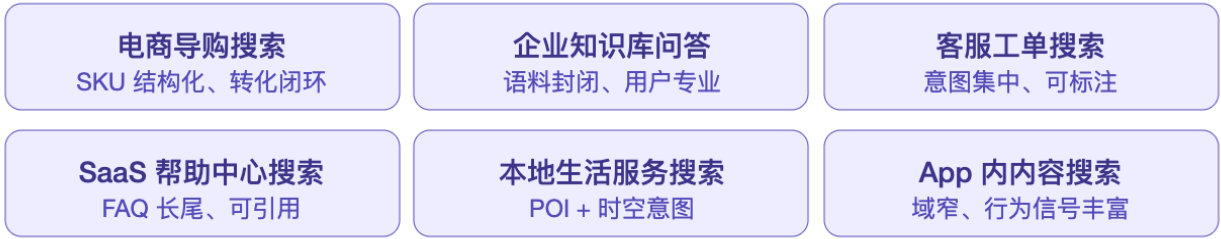
7.2 优先级 2：把 LLM 当“搜索规划器”，不是唯一答案源



拆解路径

7.3 优先级 3：垂直场景优先

这些场景的数据边界更清楚，答案标准更容易定义，业务指标也更直接。



垂类场景举例

8. 一个 PM 判断框架

可以用四个维度判断一个 LLM 搜索项目值不值得做：

- 语义增益：传统关键词搜索是不是明显理解不了？
- 证据可得性：有没有高质量、可检索、可引用的数据源？
- 错误代价：答错会不会造成严重后果？
- 商业闭环：能不能改善转化、留存、效率或成本？

最适合的项目是：语义增益大、证据可得、错误代价可控、商业闭环清楚。

9. 关键判断

1. **LLM + 搜索已经是明确工业趋势，不是概念**：Google、Microsoft、OpenAI、Amazon、Perplexity、阿里系都有公开产品或论文进展。
2. **最成熟的不是“端到端替代搜索”，而是 Query 理解、答案综合、引用展示和垂直搜索增强。**
3. LLM 搜索的核心产品矛盾是：**用户想要直接答案，但搜索系统必须保留证据、选择权和纠错能力。**
4. 短期最可靠的落地方式：**LLM 做检索规划 + 传统搜索/数据库做证据 + LLM 做带引用总结。**
5. 长期最有想象力的方向：**搜索、浏览器和 Agent 融合，搜索从“信息入口”变成“任务入口”。**

10. 参考来源

- [Google: Expanding AI Overviews and introducing AI Mode](#)
- [Google: AI Mode updates from Google I/O 2025](#)
- [Google: AI Overviews expanding to more than 100 countries](#)
- [Google: What happened with AI Overviews and next steps](#)
- [OpenAI: Introducing ChatGPT search](#)
- [OpenAI: Introducing ChatGPT Atlas](#)
- [OpenAI: Introducing ChatGPT agent](#)
- [Bing: Introducing Bing generative search](#)
- [Amazon: Rufus generative AI shopping assistant](#)
- [Google Cloud: RAG and grounding on Vertex A](#)
- [Microsoft Research: Large Language Models Can Accurately Predict Searcher Preferences](#)
- [ACL 2024: Synergistic Interplay between Search and LLMs for Information Retrieval](#)

- [arXiv: Large Language Model based Long-tail Query Rewriting in Taobao Search](#)
- [arXiv: LEAPS, an LLM-Empowered Adaptive Plugin for Taobao AI Search](#)