

推荐PM手把手入门第6讲：经典框架“召回、粗排、精排、重排”，这四层结构到底在干什么？

嘿，我是  大厂策略产品搬砖狗，又见面了。


最近跟几个刚转岗做推荐的 PM 聊天，发现大家对"召回、粗排、精排、重排"这套框架都听过，但真要说清楚每层在干啥、为什么要分这么多层，就开始含糊了。要么直接跳到"召回就是海选、精排就是算分"，要么陷入算法细节出不来。

说实话，我刚接触推荐的时候也是这样。那会儿算法同学跟我讲："我们这个模块做了三路召回、双塔模型、GBDT 粗排..."，我内心 OS 是："所以呢？这跟我要解决的留存问题有啥关系？"

后来慢慢发现，PM 理解推荐框架的关键，不是记住每层用什么模型，而是搞清楚每层在解决什么问题、为什么要这么设计、以及我们能在哪些环节插手。今天这篇，我就试着用 PM 视角，把这套四层结构掰开揉碎讲清楚。

一、为什么要分四层？一层不行吗？

这张图基本就是推荐系统的全貌了，接下来我们逐层拆解。



推荐架构构成

在讲每层具体干啥之前，先说说为什么要搞这么复杂。

想象一下，你面前有 **1 亿条内容**，需要给用户推荐 20 条。如果只用一个模型从头到尾算一遍，会发生什么？

计算量爆炸。精排模型通常很重（几百维特征、深度神经网络），跑 1 亿次预测，服务器直接烧掉，响应时间可能几十秒，用户早就退出了。

所以推荐系统的设计逻辑是：**用不同精度的筛子，逐层过滤**。

- 第一层（召回）：用最快的方法，从 1 亿筛到 1 万
- 第二层（粗排）：用轻量模型，从 1 万筛到 500
- 第三层（精排）：用重模型，从 500 筛到 50
- 第四层（重排）：调整顺序，从 50 筛到最终 20

这就像漏斗，越往下越精细、越慢，但候选集越小，算力能撑得住。

二、召回：从海量到可处理

2.1 召回在干什么？

召回层的任务非常明确：**从全量内容池（可能几千万、上亿条）里，快速圈出一批"可能相关"的候选**。召回不追求精准，追求的是**覆盖和效率**。

注意关键词：**快速、可能**。

- 快速：意味着不能用复杂模型，通常是**毫秒级**完成
- 可能：意味着允许漏、允许不准，只要"八九不离十"就行

2.2 召回怎么做？

召回通常会设计**多路召回策略**，每路负责一个角度：

- **兴趣召回**：用户喜欢美食，就召回美食类内容
- **协同召回**：跟你相似的用户喜欢的内容
- **热门召回**：近期爆款、高互动内容

- **关注召回**：用户关注的作者发的新内容
- **实时召回**：用户刚搜过"健身"，召回相关内容

每路召回出几百到几千条，合并去重后，可能有 1-2 万条候选。

技术上，召回常用：**向量检索**（Embedding 相似度）、**倒排索引**（标签匹配）、**协同过滤**（UserCF/ItemCF）等。这些方法的共同点是**空间换时间**——提前建好索引，查询时直接查表，非常快。

2.3 PM 在召回层能做什么？

很多人觉得召回是算法的事，PM 插不上手。其实不是。**PM 的价值在于：**

1. **设计召回策略组合**：根据业务目标，决定开哪几路召回、每路占多大比例
 - 举个例子：如果平台要扶持新作者，你可以推动增加"新作者召回"这一路
 - 如果用户冷启动体验差，你可以要求"热门召回"占比提高
2. **定义召回的"相关性"**：什么叫相关？是标签匹配？还是用户行为相似？
 - 举个例子：美食类内容，是按菜系召回（川菜、粤菜），还是按场景（快手菜、宴客菜）？这是产品定义的
3. **监控召回质量**：虽然召回允许不精准，但不能太离谱
 - 你需要看：每路召回的点击率、召回覆盖度（是否有用户召回不到内容）、召回多样性等

一个真实场景：比如我们发现新用户留存很差，拆数据发现是召回阶段就出了问题——新用户没有行为数据，兴趣召回基本失效，只剩热门召回在撑着，导致内容同质化严重。这时候可以推动增加了"新用户冷启动召回"（基于注册信息、地域等），留存大概率会明显改善。

三、粗排：快速打分，初步排序

3.1 粗排在干什么？

召回给了你 1 万条候选，但 1 万条还是太多了，不可能全扔给精排（精排模型太重，算不动）。

粗排的任务是：**用一个轻量级模型，给这 1 万条内容快速打个分，筛出 500-1000 条相对靠谱的。**

粗排的定位：比召回精准，但比精排粗糙。它像个"预筛"，帮精排减轻负担。

3.2 粗排怎么做？

粗排通常用 **轻量模型**，比如：

- **线性模型**（LR）：几十个特征，毫秒级预测
- **简单树模型**（GBDT 浅层）：几百棵树，快速打分
- **双塔模型**（轻量版）：用户塔和物品塔分别算 Embedding，点积得分

特征上，粗排用的是 **易获取、计算快** 的特征：

- 用户基础属性（年龄、性别、活跃度）
- 内容基础属性（类目、发布时间、热度）
- 简单交叉特征（用户类目偏好 × 内容类目）

不会用的特征：

- 复杂交叉特征（计算慢）
- 实时特征（来不及算）
- 长序列特征（内存占用大）

3.3 PM在粗排层能做什么？

粗排层PM能插手的空间相对小，但也有几个关键点：

1. **平衡粗排的精度和速度**：粗排太粗，会把好内容误杀；粗排太精，算力撑不住
 - 你需要跟算法对齐：粗排的目标是"不漏好货"，而不是"排得完美"
2. **关注粗排的"误伤率"**：看看被粗排刷掉的内容里，有多少其实是好内容（在精排会排前面的）
 - 如果误伤率高，说明粗排太粗暴，需要优化
3. **推动粗排升级**：粗排模型通常比精排迭代慢，你可以推动算法把精排的好特征、好模型"降维"到粗排

一个经验：粗排层很容易被忽视，因为它夹在中间，不像召回（策略明显）和精排（效果明显）那么显眼。但粗排如果做得不好，精排再强也没用——精排只能在粗排给的 500 条里选，如果这 500 条本身就很差，精排也救不回来。

四、精排：重模型，精准预估

4.1 精排在干什么？

精排是推荐系统的**核心环节**，它的任务是：**用最强的模型，给每条候选内容算一个精准的预估分，然后排序。**

精排追求的是**准**，为了准，可以用上所有能用的特征、最复杂的模型。

4.2 精排怎么做？

精排通常用**深度学习模型**，比如：

- **DNN**（深度神经网络）：多层全连接
- **Wide & Deep**：结合记忆和泛化
- **DeepFM**：自动学习特征交叉
- **双塔 + 交叉塔**：召回和精排统一框架


特征上，精排会用上**几百甚至上千维特征**：

- 用户长期兴趣（历史行为序列）
- 用户短期兴趣（近期点击、搜索）
- 内容多维特征（标题、封面、标签、作者）
- 上下文特征（时间、地域、场景）
- 统计特征（内容历史 CTR、用户历史活跃度）
- 实时特征（刚发生的行为）

精排的**目标**通常是预估用户对内容的**多目标分**，比如：

- 点击率（CTR）
- 点赞率（Like）
- 评论率（Comment）
- 完播率（Finish）
- 停留时长（Duration）

然后通过**多目标融合**（加权、连乘等），得到最终的排序分。这个过程看起来很"算法"，但 PM 其实有很多可以发挥的地方。



精排模型情况

4.3 PM在精排层能做什么？

精排是PM和算法协作最紧密的环节，你的价值主要体现在：

1. 定义优化目标：精排要预估哪些目标？权重怎么配？

- 举个例子：如果你发现用户完播率很低，你可以推动提高"完播率"在融合公式里的权重
- 如果要提升社区活跃，你可以加入"评论率"作为目标

2. 设计实验，验证模型效果：精排模型迭代很频繁，每次上线前都要做 AB 实验

- 你需要设计实验方案、选择核心指标、解读实验结果
- 不是模型准确率高就一定好，要看业务指标（留存、时长、GMV 等）

3. 诊断模型问题：当精排效果不好时，你要能 case study，找出问题

- 举个例子：如果发现某类内容曝光很低，可能是精排模型对这类内容预估偏低，需要 badcase 分析

4. 推动特征建设：精排的效果很大程度取决于特征质量

- 你可以从业务角度提需求："能不能加上用户最近搜索的关键词作为特征？"
- 你可以推动数据建设："我们需要埋点记录用户的完播行为"

一个真实场景：比如你发现精排模型对新内容预估很保守（因为新内容没有历史数据），导致新内容曝光不足。可以推动算法加入了"内容新鲜度"作为特征，并在融合公式里给新内容一定加权，新内容生态大概率会明显改善。

五、重排：业务规则，最后调优


5.1 重排在干什么？

精排给出了一个分数排序的列表，但这个列表可能还有问题：

- 前 10 条都是同一个作者的内容（重复）
- 连续 5 条都是美食（单调）
- 广告、运营位还没插入
- 某些内容需要降权（低质、违规边缘）
- 某些内容需要提权（扶持新作者、平台重点内容）

重排的任务就是：在精排的基础上，用业务规则做最后的调整，让最终展示的列表符合产品和运营的要求。

5.2 重排怎么做？



打散 (Diversity) :

- 同作者打散: 同一个作者的内容不能连续出现
- 同类目打散: 同一类目的内容要间隔展示
- 同形式打散: 图文、视频交替出现

插入 (Insertion) :

- 广告插入: 在固定位置或按规则插入广告
- 运营位插入: 插入平台推荐、活动入口等

提权/降权 (Boosting/Demotion) :

- 新作者提权: 给新作者的内容加分, 增加曝光
- 低质内容降权: 对标题党、低俗内容降权
- 已读降权: 用户看过的内容降权或过滤

去重 (Deduplication) :

- 内容去重: 相似内容只保留一条
- 已读去重: 用户看过的内容不再推荐### 5.3 PM 在重排层能做什么?

重排是PM最能发挥的环节, 因为这里主要是**产品策略和业务规则**, 而不是算法模型。

PM的核心工作:

1. **设计重排规则:** 根据产品目标, 定义哪些规则、优先级如何
 - 举个例子: 如果要扶持新作者, 你可以设计"新作者提权 20%, 且位置不能低于第 5 位"
 - 如果要提升多样性, 你可以设计"同类目间隔至少 2 条, 同作者间隔至少 3 条"
2. **平衡规则冲突:** 多条规则可能互相冲突, 你需要定义优先级
 - 举个例子: 广告插入 vs 打散规则, 如果广告插入会破坏打散, 怎么办?
3. **监控重排效果:** 看重排后的多样性、打散效果、提权效果等
 - 你可以看: 同作者平均间隔、同类目平均间隔、新作者曝光占比等
4. **快速迭代:** 重排规则可以随时调整, 不需要重新训练模型
 - 举个例子: 发现某类内容曝光过高, 可以立刻加一条降权规则

一个真实场景：某次大促，运营要求在推荐流里插入活动入口。最初算法直接插在第 3 位，但发现这打断了用户浏览节奏，点击率和停留时长都下降了。后来调整策略：根据用户行为动态插入（活跃用户第 3 位，非活跃用户第 5 位），并且插入后下一条内容强制推荐高分内容，效果明显改善。

六、四层结构的协同：整体大于部分之和

讲完四层，再拉回来看整体。

推荐系统不是四个独立的模块，而是一个 **协同工作的漏斗**。每层的设计，都要考虑上下游的影响：

- **召回影响粗排：**召回质量不好，粗排再强也选不出好内容
- **粗排影响精排：**粗排误杀了好内容，精排永远看不到
- **精排影响重排：**精排打分不准，重排再怎么调也救不回来
- **重排影响召回：**重排的策略（比如打散），会反馈到召回（需要召回更多多样化的内容）

一个典型的协同场景：

假设你要提升内容多样性，不能只在重排层打散，需要 **四层联动**：

- **召回层：**增加多样性召回路（冷门类目、小众兴趣）
- **粗排层：**不要对冷门内容一刀切，给一定容忍度
- **精排层：**在融合公式里加入"多样性分"，鼓励预估不同类目
- **重排层：**打散规则，保证最终展示的多样性

只优化一层，效果往往有限；四层联动，才能真正解决问题。

七、PM的视角：不是调参，而是定义"好"

讲了这么多，最后说说我对PM在推荐框架里角色的理解。

很多人觉得推荐系统是算法的领域，PM 只能打打杂、提提需求。其实不是。

PM 在推荐里的核心价值，是定义"什么是好的推荐"。算法负责实现，PM 负责定义。

举个例子：

- 算法说："我可以把点击率预估准确率提升 2%"
- PM 要问："点击率提升 2%，对留存、时长、GMV 有什么影响？这个方向对吗？"
- 算法说："我可以加一个新特征，AUC 提升 0.5%"
- PM 要问："这个特征的业务含义是什么？会不会带来副作用（比如让老用户看不到新内容）？"

PM不需要懂模型细节，但需要懂业务逻辑、懂用户体验、懂生态平衡。你要能从产品视角，把业务目标翻译成算法语言，再把算法结果翻译回业务收益。

这是 PM 在推荐系统里不可替代的价值。

写在最后

召回、粗排、精排、重排，这套四层框架，是推荐系统的经典架构，也是业界主流做法。

但它不是金科玉律，不同业务、不同阶段，可能有不同的设计：

- 小公司可能只有召回+精排，没有粗排（因为候选量不大）
- 有些平台会在精排后加"混排"（多个频道的内容混在一起）
- 有些业务会把重排拆成"业务重排"和"展示重排"两层

关键不是记住这四层，而是理解**分层设计的思想：用不同精度的筛子，平衡效果和效率。**

以及，理解**PM在每层能做什么、怎么和算法协作、如何把业务目标落地到技术实现。**

这是我这几年做推荐的感悟。

希望这篇能帮到你。

如果有问题，评论区见。