

推荐PM手把手入门第11讲：多目标建模，又要点击又要转发还要购买，算法怎么权衡？

👉 上一讲我们聊了精排模型从 LR 到深度学习的演进，本质上都是在预估"一个目标"。但现实中的推荐场景，远没有那么简单。

有同学后台咨询我，说自己刚接手推荐模块的时候，运营同学提了个需求："能不能让用户既多看内容，又多互动，还能多下单？" 他当时想得很简单：那就让算法同时预估点击、点赞、下单三个概率呗，全加起来不就行了？结果上线后数据一塌糊涂。点击涨了，但都是标题党；互动涨了，但转化率暴跌；GMV 确实涨了点，但用户时长掉得厉害，留存也在往下走。


这就是多目标建模最核心的矛盾：不同目标之间往往是冲突的，简单粗暴地叠加，只会让系统失控。

今天这篇，我想跟你聊聊下面几个问题，依然不讲公式，只讲产品逻辑和决策框架：

- 为什么推荐一定要做多目标
- 多目标建模的几种主流方案
- PM 怎么参与多目标权衡的决策

一、为什么单目标不够用？

早期的推荐系统，目标很单纯：让用户多点。所以模型只预估一个 CTR（点击率），谁的点击率高就推谁。但这套逻辑很快就暴露出问题。



多目标冲突示意图

1. 短期目标 vs 长期价值

点击率高不等于用户满意。举个例子，标题党、擦边球内容的点击率往往很高，但用户点进去发现内容货不对板，会立刻划走，甚至对平台产生负面印象。长期来看，这种内容会伤害用户留存和口碑。

所以我们不能只看点击，还得看：

- **停留时长**：用户真的看完了吗？
- **互动行为**：点赞、评论、转发，代表内容质量
- **负反馈**：不感兴趣、举报，是用户在"用脚投票"

2. 平台商业化需求

推荐不是慈善事业，平台要活下去。对于电商、内容社区来说，除了用户体验，还得考虑商业化：

- 电商要看 **下单率、GMV**
- 内容平台要看 **广告点击、会员转化**
- 社交平台要看 **关注、私信、社交链建立**

单纯优化点击，可能让用户爽了，但平台赚不到钱；单纯优化转化，用户体验又会崩。

3. 生态平衡问题


推荐还得照顾内容生态：

- **创作者侧**：新人、腰部创作者需要扶持，不能让头部吃光所有流量
- **多样性**：不能总推同质化内容，用户会审美疲劳
- **时效性**：新内容要有机会冒出来，不能让老内容霸榜

所以，现代推荐系统一定是多目标的——你得在点击、时长、互动、转化、生态健康之间找平衡。

二、多目标建模的三种主流方案

面对多个目标，算法怎么建模？主流有三种思路：加权融合、多任务学习、层次化建模。



三种多目标建模方案对比

方案一：加权融合

最直观的做法：让模型分别预估每个目标的概率，然后按权重加起来。

公式长这样（别怕，我不展开）：

代码块

```
1 最终得分 = w1 × CTR + w2 × 点赞率 + w3 × 转化率
```

这个方案的好处是 **简单、可控**。PM 可以直接调权重：

- 想提升互动，就把点赞权重调高
- 想冲 GMV，就把转化权重调高
- 618 大促期间，临时拉高转化权重

但问题也很明显：

1. **各目标的量纲不一样**：点击率可能是 10%，转化率可能是 0.5%，直接相加没意义。所以实际操作中，要先做归一化（比如都映射到 0-1 区间），或者用对数、分档等方式处理。
2. **权重怎么定**？w1 = 0.6，w2 = 0.3 合理吗？还是 0.5 : 0.5？没有标准答案，只能靠 AB 实验不断调优。可以先根据业务优先级拍个初版权重，然后看数据微调，看北极星指标（留存、时长、GMV）的变化。

3. 目标之间的相关性被忽略了

加权融合假设各目标是独立的，但实际上它们有强关联：

- 点击高 → 停留时长可能也高
- 互动高 → 转化率往往也不差
- 但有些内容点击高、转化低（比如纯娱乐内容）

简单加权会丢失这些关联信息。

方案二：多任务学习

多任务学习的核心思想：**让一个模型同时学习多个目标，底层共享特征，顶层各自预测。**

想象一下，模型是个人：

- 底层（共享层）：学习"这个用户喜欢什么类型的内容"
- 顶层（任务层）：基于这个理解，分别预测"他会不会点"、"会不会赞"、"会不会买"

这个架构有个专业名字叫 **Shared-Bottom 或 MMOE (Multi-gate Mixture-of-Experts)**，但作为 PM，你不用记这些，只需要理解：

多任务学习能让各目标"互相帮助"：

- 预测点击时，互动数据能提供信号
- 预测转化时，点击和时长数据能辅助判断

相比加权融合，多任务学习的好处是：

- **特征共享，训练效率高**
- **能捕捉目标间的关联**
- **各任务的预测准确率通常都会提升**

但它也有局限：

1. **任务冲突问题**：如果两个目标本身就矛盾（比如点击 vs 深度阅读），模型在训练时会"左右互搏"，最后谁都学不好。这时候需要引入 **任务平衡机制**，比如动态调整各任务的 loss 权重。

2. **PM 的可控性降低**：加权融合时，PM 还能调权重；多任务学习后，模型自己学出了目标间的关系，PM 能插手的地方变少了。你得更依赖算法同学的调参能力，或者在顶层加一个 **后融合层**，把各任务的预测结果再做一次加权。

方案三：层次化建模

有些目标有明确的 **主次关系** 或 **漏斗关系**，这时候可以用层次化建模：

举个例子，电商推荐：

1. **第一层：粗排**，快速过滤，只看 CTR
2. **第二层：精排**，同时看 CTR + 加购率
3. **第三层：重排**，综合 CTR + 加购率 + 转化率 + GMV

每一层关注的目标不一样，越往后越精细，越接近最终的商业目标。

层次化建模的好处：

- **计算资源分配更合理**：前面几层候选多，只算简单目标；后面候选少，可以上复杂模型
- **逻辑清晰，便于调试**：哪一层出问题，很容易定位

但它也有成本：

- **链路变长，延迟增加**
- **各层目标不一致，可能导致信息损失**

比较简单的做法是：粗排看 CTR，精排看 CTR + 互动，重排加入商业化目标。每一层都单独调优，最后整体看最终指标。

三、PM 怎么参与多目标权衡？

说实话，多目标建模是个 **产品 + 算法深度协作** 的过程。算法负责实现，但 **目标的优先级、上线后的观察，都需要 PM 来主导**。



PM参与多目标权衡的决策框架

1. 明确北极星指标

多目标的本质是：你不可能让所有指标都涨。所以第一步是确定 **北极星指标**（North Star Metric）：

- 内容社区：日活 × 人均时长？ 还是互动率？
- 电商平台：GMV？ 还是用户 LTV（生命周期价值）？
- 短视频：完播率？ 还是分享率？

北极星指标是你做决策的锚点。其他目标都是为它服务的。

2. 搭建目标体系

围绕北极星指标，拆解成多层目标：

举个例子，假设北极星指标是"用户留存"：

- **一级目标**：日活、次留
- **二级目标**：人均时长、互动率
- **三级目标**：点击率、完播率、点赞率
- **约束目标**：负反馈率（不能超过阈值）、商业化目标（GMV 不能跌）

这个体系要跟算法同学对齐，让他们知道哪些目标是"必须涨"，哪些是"不能跌"，哪些是"可以牺牲"。

3. 警惕"指标游戏"

多目标最大的坑是：**算法会找到你没想到的漏洞。**

一些常见案例：

- 优化"完播率"，结果模型疯狂推短视频（5秒的视频完播率天然高）
- 优化"互动率"，结果推了一堆争议内容（骂战互动率高）
- 优化"GMV"，结果推了一堆低价劣质商品（转化高但复购低）

所以 **一定要加约束条件**：

- 完播率 $\geq 80\%$ 且时长 ≥ 30 秒
- 互动率高 但负反馈率 $< 5\%$
- GMV 涨 且退货率不涨

这些约束，算法同学不一定能想到，需要 PM 根据业务 sense 来补充。

4. 长期 vs 短期的权衡

最难的是平衡短期指标和长期价值：

- 短期冲 GMV，可以多推商业化内容，但用户体验会下降
- 长期做留存，得克制商业化，但老板会问"为什么不赚钱"

常见做法是：

- **日常态**：以长期指标（留存、LTV）为主，商业化目标设下限
- **大促期间**：临时调高商业化权重，但设观察窗口，大促后立刻调回来，看留存有没有受损

多目标的本质，是在不确定中找动态平衡。

四、写在最后

多目标建模，是推荐系统从"能用"到"好用"的关键一步。

它不是一个纯技术问题，更是一个 **产品决策问题**：你要想清楚平台到底要什么，用户到底要什么，然后在算法的帮助下，找到那个脆弱的平衡点。

这个过程中，PM 的价值不是写公式，而是：

- 定义目标优先级
- 设计约束条件
- 通过实验迭代权重
- 警惕算法的副作用

算法是工具，但拿着工具的人，得知道自己要做什么。