

分享一下LLM 与推荐结合的工业界进展

口径说明：优先引用公司官方技术博客、财报/公告、会议论文、arXiv/ACL/NeurIPS 等一手来源。这里的“已应用”只表示来源明确披露了线上部署、生产系统或在线 A/B；没有披露的方向按“研究/基准/试点”处理。

1. 先给结论

LLM 和推荐的结合已经不是单纯“让 ChatGPT 帮我排几个商品”。工业界真正落地的主线有三条：

- 1. **LLM 做语义理解器**：把商品、视频、广告、用户行为转成更懂“内容含义”的标签、摘要、Embedding 或 Semantic ID。这个最稳，已经被电商、广告、内容平台大规模使用。
- 2. **LLM 技术栈改造推荐模型**：借鉴 Transformer、生成式建模、Scaling Law、MoE、KV cache、低精度推理、RL/DPO 等，把召回/排序从传统多阶段 pipeline 推向“更统一、更大、更可扩展”的推荐模型。Meta、快手、字节、小红书等已经有线上结果。
- 3. **LLM 做交互和解释层**：让用户用自然语言表达偏好、追问、比较、解释推荐原因。阿里电商和 Google 研究都在推进，但大多数场景还不会让大 LLM 直接在线替代核心推荐排序。

最关键的 PM 认知是：**工业界落地的 LLM+推荐，大多不是在线调用一个通用大模型逐个判断候选物品；而是把 LLM 的语义能力、生成式训练范式和推理链能力“蒸馏/结构化/工程化”进原有推荐系统。**

2. 推荐系统里，LLM 主要插在哪些位置

离线理解LLM 增强用户兴趣生成式召回/排序模型LLM 推理链/CoT 教师对话式推荐/导购

PM 可以把它理解成四个能力层：

能力层	通俗理解	典型收益	主要风险
语义理解	看懂“这个内容/商品到底是什么”	冷启、长尾、复杂 query、跨场景兴趣	成本、标签噪声、语义过度泛化
用户兴趣建模	把用户行为翻译成更细的兴趣	长短期兴趣、跨场景迁移、推荐惊喜感	实时性、隐私、兴趣漂移
生成式召回/排序	像生成下一个 token 一样生成下一个物品/物品序列	更强序列建模、更统一 pipeline、可吃到 scaling law	候选空间约束、延迟、线上稳定性
交互/解释	用户能说“不要这种、换成更便宜/更正式的”	可控推荐、导购、解释、转化	幻觉、解释不等于真实因果、对话成本

3. 工业界进展雷达

公司/场景	做了什么	是否已应用	披露效果	PM 应该怎么理解
Meta: HSTU / Generative Recommenders	把推荐问题改写成生成式序列建模，提出 HSTU 架构，支持万亿参数级推荐模型	已上线	1.5T 参数 HSTU 在多个十亿用户级 surface 部署，在线 A/B 指标提升 12.4%	这是“推荐也能吃 scaling law”的里程碑，不是通用聊天 LLM，而是推荐专用生成式模型
Meta: Ads Adaptive Ranking Model	广告排序使用 LLM-scale 复杂度模型，通过请求级复用、模型系统协同、FP8 等保证低延迟	已上线	2025 Q4 上线 Instagram；目标用户广告转化 +3%，广告 CTR +5%；O(100ms) 延迟	大模型能进广告精排，但必须把算力复用和推理系统一起设计
快手: OneRec	用一个端到端生成式模型统一召回和排序，按 session 生成推荐结果，并用 DPO/RL 对齐偏好	已上线	主场景部署，watch-time +1.6%	快手证明“生成式推荐”可以进入主 App 核心推荐，而不是只做旁路实验
快手: OneRec-V2	把 OneRec 继续工程化，用 Lazy Decoder-Only 降低编码瓶颈，扩展到 8B 参数	已线上 A/B/迭代	总计算量 -94%，训练资源 -90%；App Stay Time +0.467% / +0.741%	第二代重点从“能不能有效”转向“能不能便宜、稳定、可扩展”
快手电商: OneMall	把生成式推荐迁移到商品卡、短视频带货、直播等电商场景	已上线	服务 4 亿+ DAU；商品卡 GMV +13.01%，短视频订单 +15.32%，直播订单 +2.78%	生成式推荐不只适合内容流，也能用在强商业目标场景
快手本地生活: OneLoc	在生成式推荐里显式加入地理位置、距离、GMV 等多目标	已上线	服务 4 亿日活；GMV +21.016%，订单 +17.891%	LLM/生成式模型仍要吃业务约束；“懂兴趣”不等于“懂距离和交易目标”
阿里淘宝/天猫 11.11	基于 Qwen 后训练，增强 20 亿商品索引、搜索、推荐、广告与导购	已大规模应用	复杂 query 搜索相关性 +20 个百分点，部分推荐点击双位数提升，AI 出价 ROI +12%	电商最先落地的是“商品语义组织 + 搜索推荐匹配 + 商家工具”组合拳
阿里: FilterLLM	冷启推荐从“逐个用户-物品判断”改成“文本到用户分布预测”	已部署	在阿里平台服务 2 个月，处理超过 10 亿冷启动物品，效率提升 30 倍以上	冷启是 LLM 最适合切入的推荐问题之一，因为新物品没有行为但有内容
腾讯广告: SCoTER	让 LLM 发现推理模式，再把结构化 CoT 转移到轻量推荐模型，避免线上 LLM 成本	已生产部署	腾讯广告平台 GMV +2.14%，且消除线上 LLM 推理成本	很典型的落地方式：LLM 当老师，线上还是轻量模型
腾讯广告: 全模态生成式推荐竞赛	发布来自真实脱敏广告日志的 TencentGR-1M/10M 数据集，推动全模态生成式推荐	研究/生态基准	2025 年竞赛 6000+ 申请者；2026 年发布数据集论文	说明广告推荐正从 ID/特征走向“多模态 token + 自回归建模”
字节: LONGER	面向超长用户行为序列的 Transformer 推荐模型，采用 KV cache、混合精度等 LLM 工程技巧	已上线	字节广告和电商 10+ 场景全量部署，服务十亿级用户	不是聊天 LLM，但代表 LLM 技术栈进入推荐长序列建模
	用一个 Transformer 统一特征交		per-user GMV	传统推荐里“特征交互模

字节： OneTrans	用 LLM Transformer 做物品交互和用户序列建模，支持跨请求 KV cache	已线上 A/B	per-user CTR +5.68%，WWW 2026 accepted	块”和“序列模块”开始合并成大一统 Transformer
RedNote/小红书：RED-Rec	LLM-enhanced 双塔框架，统一搜索、浏览、发现等多场景用户兴趣	已线上 A/B	在数亿用户上验证，对内容推荐和广告投放均有提升	LLM 能帮助“跨场景用户理解”，不是每个场景各训一个孤岛模型
小红书 Explore Feed： GenRank/ RankGPT	在探索 Feed 的 ranking 阶段验证生成式排序	已线上 A/B	数亿用户级推荐场景，接近现有生产资源下用户满意度显著提升	生成式排序开始替代/增强精排，但重点是架构效率，不是无脑加大模型
小红书搜索：GRM + RL	把搜索相关性建模成带业务标准的推理任务，用 RL 训练再蒸馏到轻量模型	已线上 A/B	KDD 2026 ADS Track；离线和在线业务指标显著提升	LLM 的“推理”在搜索推荐里更适合作为可蒸馏的相关性判断框架
Google：TIGER	用 Semantic ID 表示物品，Transformer 自回归生成下一个物品 ID	研究/未披露生产	NeurIPS 2023，多个数据集优于当时 SOTA，冷启动泛化更好	这是生成式召回的基础范式，但公开来源未说明 Google 已大规模上线
Google：REGEN	用自然语言 critique、购买理由、个性化叙述构造对话推荐 benchmark	研究/数据集	用户 critique 可提升 Recall@10；探索 hybrid 与纯 LLM 端到端方案	对话式推荐还在补数据和评估短板，不应直接等同于核心 feed 可上线
大型职业社交网络：SLM for Rec	通过蒸馏、剪枝、量化，把 LLM 能力压缩成可服务的小模型	工业经验/应用场景披露	EMNLP 2025 Industry Track，总结多个搜索和推荐用例	另一个强信号：产业共识不是“线上直接跑最大 LLM”，而是压缩后服务

4. 哪些能力已经比较成熟

4.1 内容和商品语义理解：最成熟

推荐过去依赖 ID、类目、标签、作者、协同过滤。LLM/MLLM 的新增价值是能读懂标题、评论、图像、视频和复杂 query，比如：

- 商品是“通勤可穿的黑色小西装”，不只是“女装 > 外套”。
- 视频是“新手健身纠正动作”，不只是“健身内容”。
- 用户 query 是“我家两岁半女儿不爱刷牙买什么”，不是关键词“牙刷”。

阿里 11.11 的官方披露很典型：先给 20 亿商品补充上下文和索引，再把 LLM 接到搜索、推荐和广告引擎上，结果是复杂 query 相关性、推荐点击和广告 ROI 都提升。

4.2 冷启动和长尾：非常适合 LLM

冷启动物品没有点击/购买历史，传统协同过滤很弱，但 LLM 可以先读内容。FilterLLM 的思路是：不要让 LLM 对“每个用户-物品 pair”逐个打分，而是一次预测这个新物品可能适合哪类用户分布。这样把 LLM 从昂贵判断器变成高效过滤器。


4.3 长序列用户兴趣：正在快速工程化

短视频、电商、广告用户行为很长。LLM 技术栈里的 Transformer、KV cache、混合精度、MoE、低精度推理被迁移到推荐中，用来吃更长历史。字节 LONGER、OneTrans 和 Meta Adaptive Ranking 都属于这条线。

PM 要听懂的点：**用户历史更长不一定更好，关键是模型能不能在低延迟里提炼出“此刻有用”的兴趣。**

4.4 生成式召回/排序：头部平台已落地，但门槛高

生成式推荐不是“生成文案”，而是把物品也 token 化，让模型像生成一句话一样生成“下一个可能喜欢的物品/物品序列”。



这条线的已落地证据最强来自 Meta HSTU、快手 OneRec 系列、小红书 GenRank/RankGPT。它的价值在于统一建模、长序列能力、可扩展性；难点是推理延迟、候选空间约束、训练/服务成本和线上稳定性。

4.5 LLM 推理能力：更适合“老师”和“裁判”，不是直接线上逐条思考

腾讯 SCoTER、小红书搜索 GRM、快手 OneRec-Think 都在尝试让推荐系统具备显式推理能力。但工业做法通常是：

1. 用大模型生成或发现推理模式。

- 2. 用业务反馈/RL/DPO 让推理更贴近点击、GMV、停留、相关性。
- 3. 把结果蒸馏到轻量模型，线上低延迟服务。

这说明“推理”有价值，但**直接让大模型在线 chain-of-thought 排序全量候选，通常成本和延迟不可接受。**

5. 现在的能力边界

边界	PM 应该怎么判断
延迟边界	Feed/广告推荐通常是百毫秒级，聊天 LLM 的秒级响应不能直接搬进核心排序。能上线的方案都在做请求级复用、缓存、量化、蒸馏或小模型化。
成本边界	大模型的收益必须覆盖 GPU/推理成本。Meta 强调“inference trilemma”，快手 OneRec-V2 重点解决计费分配，说明成本是核心约束。
候选空间边界	LLM 自然语言输出可能生成不存在的商品/视频。工业方案通常使用 Semantic ID、约束解码或映射表，把输出限制在真实库存里。
多目标边界	推荐不只追 CTR，还要停留、GMV、广告 ROI、用户体验、多样性、安全、频控。OneLoc、OneMall、SCoTER 都说明必须把业务目标写进 reward 或策略层。
实时性边界	用户兴趣、库存、价格、热点都在变。LLM 学到的世界知识不等于实时平台状态，仍然需要实时特征、索引刷新和在线反馈闭环。
解释边界	LLM 能生成“听起来合理”的解释，但解释不一定是真实排序原因。解释层要和真实特征、召回/排序证据绑定，否则会变成幻觉文案。
数据偏差边界	推荐训练数据来自历史曝光，天然有位置偏差、流行度偏差和平台策略偏差。LLM 可以补语义，但不会自动解决样本选择偏差。
组织边界	这不是单个算法模块升级，而是内容理解、索引、训练、推理、A/B、策略、商业目标一起改。头部平台落地快，是因为基础设施强。

6. PM 该怎么听懂技术同学的说法

技术词	PM 版解释	关键追问
Semantic ID	给每个物品一个“有语义的 token 编号”，模型可以生成这些编号	这个 ID 如何更新？新物品如何进索引？会不会多个物品撞 ID？
Generative Retrieval	模型直接生成候选物品 ID，而不是向量库里最近邻搜索	生成的候选覆盖率如何？无效 ID 怎么处理？和现有召回如何融合？
HSTU / GenRank / OneRec	推荐专用的生成式/Transformer 架构	是替代哪一层：召回、粗排、精排，还是全链路？
DPO / RLHF / Preference Alignment	用用户反馈或 reward 让模型更符合业务目标	reward 是点击、停留、GMV、长期留存还是多目标？有没有 reward hacking？
CoT Distillation	让大模型先“想明白”，再把推理模式教给小模型	线上是否还跑大模型？如果不跑，推理信息如何保真？
MoE	只激活一部分专家参数，提升模型容量但控制计算量	专家路由是否稳定？长尾/新用户会不会路由不好？
KV Cache	缓存历史序列中间结果，减少重复计算	用户行为更新后缓存如何失效？跨请求复用是否影响实时性？
MFU	GPU 有效算力利用率	线上延迟、吞吐、成本比现有模型如何？

7. 对推荐 PM 的落地建议

优先级 1：先找“语义增益大、线上风险小”的入口

适合先做：


- 新内容/新商品冷启动。
- 复杂搜索 query 理解。
- 商品/视频多模态标签、摘要、卖点抽取。
- 用户兴趣摘要，作为召回/排序辅助特征。
- 推荐解释，但必须绑定真实排序证据。

不建议一开始就做：

- 直接让大 LLM 在线重排全量候选。
- 用自由文本生成真实商品/视频 ID。
- 没有约束地让模型优化 GMV 或停留。

优先级 2：把 LLM 当“特征生产机”和“老师”

更稳的工业路径：




这个路径牺牲了一部分“通用推理自由度”，换来成本、稳定性和可控性。

优先级 3：如果要做生成式推荐，先明确替换哪一层

生成式推荐可以有三种切入：

切入点	难度	适合场景
生成式召回	中高	候选多、冷启动多、需要语义泛化
生成式精排/重排	高	头部平台成熟 feed，追求 0.5%-3% 增益
端到端统一召回排序	很高	超大 DAU、强基础设施、能承受长期重构

8. 一个 PM 判断框架



推荐PM对AI应用的判断框架

9. 关键判断

1. **已应用，不是纯概念**：Meta、快手、阿里、腾讯、字节、小红书/RedNote 都有明确线上部署或 A/B 证据。
2. **但不是所有“LLM+推荐”都已成熟**：对话式推荐、端到端纯 LLM 推荐、开放式自然语言生成物品仍然有明显工程和评估边界。
3. **最可靠的短期落地方式**：LLM 离线语义增强 + 小模型线上服务。
4. **最具战略性的长期方向**：推荐模型 Transformer 化、生成式化、统一化，逐步吃到 scaling law。
5. **PM 最应该关注的不是模型名字，而是**：它替换哪一层、带来什么业务增量、线上延迟成本多少、是否可控、是否已经 A/B 证明。

10. 参考来源

- Meta Engineering: [Meta Adaptive Ranking Model: Bending the Inference Scaling Curve to Serve LLM-Scale Models for Ads](#)

- Meta / ICML 2024: [Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations](#)
- Meta open source: [meta-recsys/generative-recommenders](#)
- 快手 OneRec: [OneRec: Unifying Retrieve and Rank with Generative Recommender and Iterative Preference Alignment](#)
- 快手 OneRec-V2: [OneRec-V2 Technical Report](#)
- 快手 OneMall: [OneMall: One Architecture, More Scenarios](#)
- 快手 OneLoc: [OneLoc: Geo-Aware Generative Recommender Systems for Local Life Service](#)
- 快手财报/业务披露: [Kuaishou Technology Q3 2025 Results](#)
- 阿里官方: [AI Powers Large-scale Applications at the World' s Largest Shopping Festival](#)
- 阿里 FilterLLM: [FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#)
- 腾讯 SCoTER: [SCoTER: Structured Chain-of-Thought Transfer for Enhanced Recommendation](#)
- 腾讯官方: [Tencent Hosts China' s First All-Modal Generative Recommendation Competition](#)
- 腾讯 TAAC2025: [Tencent Advertising Algorithm Challenge 2025: All-Modality Generative Recommendation](#)
- 字节 LONGER: [LONGER: Scaling Up Long Sequence Modeling in Industrial Recommenders](#)
- 字节 OneTrans: [OneTrans: Unified Feature Interaction and Sequence Modeling with One Transformer in Industrial Recommender](#)
- RedNote/小红书 RED-Rec: [Cross-Scenario Unified Modeling of User Interests at Billion Scale](#)
- 小红书 GenRank/RankGPT: [Towards Large-scale Generative Ranking](#)
- 小红书搜索 GRM + RL: [Optimizing Generative Ranking Relevance via Reinforcement Learning in Xiaohongshu Search](#)
- Google Research: [REGEN: Empowering personalized recommendations with natural language](#)
- Google / NeurIPS 2023: [Recommender Systems with Generative Retrieval](#)
- ACL EMNLP Industry 2025: [Scaling Down, Serving Fast: Compressing and Deploying Efficient LLMs for Recommendation Systems](#)
- ACL EMNLP 2025: [Real-time Ad Retrieval via LLM-generative Commercial Intention for Sponsored Search Advertising](#)