

推荐PM手把手入门第22讲：智能补贴，基于Uplift 模型的红包发放策略


👉 前段时间和一位业务同学聊天，他吐槽了一个很常见的问题：“每个月花几百万发红包，但效果总觉得不对。有些用户不发也会下单，有些用户发了也没反应，能不能更精准一点？”

这个问题，其实暴露了很多补贴策略里的一个核心误区——我们习惯按“用户价值”分层发补贴，却很少去想：**补贴到底会不会改变这个用户的行为。**

如果补贴给了本来就会下单的人，或者给了怎么都不会被影响的人，那再精细的分层，本质上都是浪费。也正因为如此，补贴策略真正该解决的不是“谁更值钱”，而是“谁对补贴敏感”。

这正是 **Uplift 模型** 要回答的问题。

传统补贴策略的困境：花钱≠有效



智能补贴的核心问题

我们先来看看传统补贴策略的典型玩法。大部分平台的补贴逻辑是这样的：

- **高价值用户**（如月消费1000+）：发30元红包
- **中价值用户**（月消费300-1000）：发10元红包
- **低价值用户**（月消费<300）：发5元红包或不发

这套逻辑的核心假设是：**价值越高的用户，越值得投入更多补贴。**

但实际跑下来，发现了几个反直觉的现象：

- **现象1：很多高价值用户，不发红包也会买。**举个例子，有个用户每周固定在平台买生鲜，已经形成习惯了。你给他发30元红包，他确实会用，但他本来就要买的。这30元本质上是"白送"的，并没有创造增量。
- **现象2：部分低价值用户，发了红包也没用。**还有一类用户，可能只是偶然下载了App，从来不开。你给他发红包，他连看都不看。这类用户对补贴完全不敏感，投入再多也是浪费。
- **现象3：真正应该重点补贴的，可能是"中间用户"。**反而是那些有一定使用习惯、但还没完全稳定的用户，比如每月消费2-3次的"摇摆用户"，一个合适的红包可能就能把他们拉回来，形成更高频的使用习惯。

这里的核心问题是：**传统分层只看用户的"当前价值"，但没有评估补贴对用户行为的"增量影响"。**

我们需要换个思路：不是问"谁更值钱"，而是问"**对谁补贴最有效**"。

Uplift 模型：找到"对补贴敏感"的那群人

这就引出了今天的主角—— **Uplift 模型（增益模型）**。

Uplift 模型的核心思想


Uplift 模型要回答的问题是：**给某个用户发红包，相比不发红包，能带来多少增量转化？**

我们把用户分成四类：

1. **确定购买者（Sure Things）**：发不发红包都会买
2. **可说服者（Persuadables）**：发红包才会买，不发就不买
3. **不可说服者（Lost Causes）**：发不发红包都不买
4. **反向用户（Sleeping Dogs）**：发红包反而不买（极少见，比如觉得平台"穷了"所以不信任）

传统分层策略无法区分这四类用户，而 Uplift 模型的目标就是**精准识别出"可说服者"**，把有限的补贴预算投给他们。

Uplift 模型：用户四分类



为什么不能直接用转化率模型？

你可能会问：我们不是已经有转化率预估模型了吗？为什么还需要 Uplift 模型？

这是个好问题。我最开始也是这么想的，直到和朋友交流后发现不是这样。

- **转化率模型预测的是：**"这个用户收到红包后，下单的概率是多少？"
- **Uplift 模型预测的是：**"这个用户收到红包后下单的概率，减去不收到红包下单的概率，差值是多少？"


举个例子：

- 用户A：收到红包下单概率90%，不收到下单概率85% → **Uplift = 5%**
- 用户B：收到红包下单概率30%，不收到下单概率5% → **Uplift = 25%**

如果用转化率模型，我们会优先给用户A发红包（90%>30%），但用户A本身就是"确定购买者"，红包只带来5%的增量。而用户B虽然基础转化率低，但红包能带来25%的增量提升，他才是真正的"可说服者"，更值得补贴。

这就是 Uplift 模型的核心价值：识别增量，而不是识别存量。

转化率模型 vs Uplift 模型




转化率模型vs uplift模型

如何训练一个 Uplift 模型？

说完原理，我们来看看实际怎么做。

Uplift 模型训练流程



uplift模型训练流程

第一步：实验设计——分桶测试

Uplift 模型的训练需要**对照实验数据**。我们需要把用户随机分成两组：

- 实验组：发红包

- **对照组：**不发红包

然后观察两组用户的行为差异。

这里有个细节要注意：**随机分桶非常重要**。如果你按照用户价值分桶（比如高价值用户都在实验组），那就没法准确评估 Uplift 了，因为你无法排除"本来就会买"的影响。

做了一个为期2周的AB测试：

- 从新用户池中随机抽取20万用户
- 实验组10万人：发10元红包
- 对照组10万人：不发红包
- 观察7天内的下单行为

第二步：特征工程——用户画像拆解

有了实验数据，接下来要构建用户特征。这些特征决定了模型能否准确识别"可说服者"。

根据和同事交流，他提供的经验，这几类特征最重要：

1. 行为活跃度特征

- 近7天/30天打开App次数
- 近期浏览商品品类数
- 加购物车但未下单次数（犹豫程度）

2. 历史消费特征

- 历史订单数
- 平均客单价
- 上次下单距今天数（流失风险）

3. 补贴敏感度特征

- 历史是否使用过优惠券
- 对折扣活动的参与率

- 客单价波动情况（说明价格敏感度）

4. 生命周期特征

- 注册天数
- 当前所处生命周期阶段（新用户/成长期/成熟期/流失期）

这里的思路是：**我们要找到那些"有一定兴趣、但还在犹豫"的用户**。他们通常具有这样的特征：

- 近期有浏览行为（有兴趣）
- 但加购未下单（在犹豫）
- 历史有使用优惠券的习惯（对价格敏感）
- 处于成长期或流失前期（还可以挽回）

第三步：模型训练——预测增量

Uplift 模型的训练方式和传统模型不太一样。常见的有两种方法。

方法1：双模型法（Two-Model Approach）

分别训练两个模型：

- 模型1：预测实验组用户的转化率 $P(Y=1|T=1, X)$
- 模型2：预测对照组用户的转化率 $P(Y=1|T=0, X)$
- $Uplift = \text{模型1预测值} - \text{模型2预测值}$

方法2：单模型法（Class Transformation）

把"是否发放红包"作为特征之一，训练一个模型预测转化率，然后通过改变这个特征值来计算 Uplift。同事团队用的是双模型法，因为更直观，也更容易向业务方解释。

模型类型方面，他们尝试过 XGBoost、LightGBM 等树模型，最终选择了 **LightGBM**，原因是：

- 训练速度快（每天要重训模型）
- 特征重要性解释性好（便于分析）
- 对类别不平衡问题鲁棒性强

第四步：模型评估——不能只看AUC

Uplift 模型的评估指标和传统分类模型不一样。

传统模型看 AUC、准确率，但 Uplift 模型要看**增量提升**。常用的指标有：

1. **Qini曲线**：横轴是覆盖用户比例，纵轴是累积增量转化数。曲线越"凸"，说明模型越能找到高 Uplift 的用户。
2. **AUUC (Area Under the Uplift Curve)**：Qini曲线下的面积，类似AUC的概念。AUUC 越大，模型效果越好。
3. **分层实验验证**：按模型预测的 Uplift 值把用户分成高、中、低三档，在每一档都做AB测试，验证实际增量是否和预测一致。

这里有个坑要提醒大家：**千万不能只看模型指标，一定要做线上AB验证**。因为 Uplift 模型对数据质量非常敏感，线下效果好不代表线上能跑通。

常见的case是线下 AUUC 很高，但线上第一次灰度测试时增量并不明显。排查原因，可能是因为训练数据里的对照组用户，有部分在其他渠道收到了红包，污染了数据。调整数据清洗逻辑后，线上效果才符合预期。

落地策略：如何在业务中应用 Uplift 模型？

有了模型，接下来就是如何落地到实际业务中。

策略1：分层补贴——按 Uplift 值分档

最直接的用法是：**按照 Uplift 值给用户分层，对不同层级给予不同的补贴策略**。

举个例子，分层是这样的：

- **高 Uplift 用户** (Top 20%)：发15-30元红包，重点投放
- **中 Uplift 用户** (20%-60%)：发5-10元红包，适度投放
- **低 Uplift 用户** (60%以下)：不发或发小额红包（如1-3元）

这里有个细节：没有给所有高 Uplift 用户发一样的红包，而是**结合用户的客单价、历史消费金额，动态调整红包面额**。


逻辑是：

- 如果用户客单价高（如200元以上），发30元红包
- 如果客单价中等（50-200元），发15元红包
- 如果客单价低（<50元），发10元红包

这样做的好处是：**在保证增量的前提下，控制补贴成本**。对于客单价高的用户，高额红包更有吸引力；对于客单价低的用户，10元也能起到刺激作用。

策略2：场景化投放——在关键节点触达

Uplift 模型不只是决定"给谁发"，还可以指导"什么时候发"。



在这些场景下，红包的增量效果最明显：

- **场景1：加购未下单后的24小时内**。用户加购物车但没结算，说明他在犹豫。这时推一个红包，转化率提升非常显著。我们当时测试，这个场景的平均 Uplift 能达到15-20%。
- **场景2：用户流失前的"黄金48小时"**。我们定义的流失是"连续7天未打开App"。在用户第5-6天未打开时，推送红包+Push，能有效召回一部分用户。
- **场景3：大促前的预热期**。大促（如618、双11）前3-5天，给中高 Uplift 用户定向发放"大促专享红包"，提前锁定这批用户的消费预算。

关键是：**不同场景下，同一个用户的 Uplift 值可能不同**。常见做法是在模型特征里加入"场景标签"，让模型学习不同场景下的增量模式。

策略3：动态调整——根据预算实时优化

补贴预算通常是有限的，我们需要在**预算约束下，最大化整体增量**。

这就涉及到一个优化问题：

$$\begin{aligned} \text{目标函数：} & \text{最大化 } \sum (Uplift_i \times \text{转化金额}_i) \\ \text{约束条件：} & \sum (\text{红包金额}_i) \leq \text{预算} \end{aligned}$$

常见的做法是：

1. 每天早上根据昨日数据，重新训练 Uplift 模型
2. 预测今天每个用户的 Uplift 值
3. 按照 $Uplift \times \text{预期转化金额}$ 从高到低排序
4. 在预算内，依次发放红包，直到预算用完

这里有个动态调整的机制：**如果上午预算消耗过快，下午会自动提高发放阈值；如果预算消耗过慢，会降低阈值。**

具体来说，可以设置了一个"消耗进度"监控：

- 如果12点前消耗超过50%预算 → 提高阈值（只给 Top 10% 的用户发）
- 如果18点前消耗不到70%预算 → 降低阈值（扩大到 Top 30%）

这样可以保证预算既不浪费，也不会过早用完。

从模型到策略：推荐PM的价值在哪？

看到这，你可能会问：这不就是算法同学的活吗？PM在其中扮演什么角色？

这恰恰是我想强调的：**Uplift 模型只是工具，如何用好这个工具，才是策略PM的核心价值。**

价值1：定义业务目标——算清楚ROI

算法同学会给你一个 Uplift 模型，但"追求什么样的 ROI，如何在增量和成本之间权衡"，这是PM要回答的问题。

举个例子，如果当时面临一个选择：

- 方案A：给 Top 10% 高 Uplift 用户发大额红包，ROI = 3.5
- 方案B：给 Top 30% 用户发中等红包，ROI = 2.8

算法同学说："方案A的ROI更高，应该选A。"

但产品分析后发现：**方案A虽然ROI高，但覆盖用户少，长期来看不利于用户习惯养成**。而方案B虽然ROI略低，但能覆盖更多"摇摆用户"，这些用户一旦养成习惯，未来的LTV（生命周期价值）会更高。

最终应该选择方案B，并设定了一个动态策略：**前3个月用方案B培养用户习惯，3个月后逐步过渡到方案A，优化ROI。**

这个决策的核心是：**平衡短期ROI和长期用户价值**。这不是算法能回答的，需要PM结合业务理解来判断。

价值2：设计实验方案——保证数据质量

Uplift 模型对实验数据非常敏感，**如何设计科学的AB测试，避免数据污染**，这是PM的基本功。

常见的几个坑如下：

坑1：对照组被污染

最开始，只在App首页做AB测试，但忽略了用户可能通过短信、Push等其他渠道收到红包。这导致对照组其实也受到了补贴影响，Uplift 被低估。

解决方案：在实验设计时，要确保对照组用户在**所有渠道**都不收到红包。比如做了一个"黑名单机制"，实验期间对照组用户无论在哪个渠道都不会收到红包。

坑2：实验周期太短

如果只做了3天实验，很多用户并不会立刻下单，而是等到周末或发工资后才下单。这导致 Uplift 被严重低估。

解决方案：延长实验周期到14天，并在分析时剔除"极端快"和"极端慢"的用户，只看7天内有行为的用户。

坑3：样本量不足

比如想测试"大额红包"的效果，但只给了5000个用户做实验。结果因为样本量太小，置信度不够，没法下结论。

解决方案：在实验前做样本量计算。通常要求每组至少5万用户，才能保证统计显著性。这些细节，算法同学不一定能cover，需要PM来把关。

价值3：策略落地——协调多方资源

有了模型和策略，落地是另一个挑战。**如何协调技术、运营、财务等多方资源，推动策略上线**，这是PM的"粘合剂"角色。

推 Uplift 模型落地，常见阻力如下：

阻力1：财务部门不理解

财务看到我们要给"部分用户"发更高额度的红包，觉得不公平，担心用户投诉。

应对方式：给财务看数据——传统策略下，很多高价值用户收到30元红包但增量为0，相当于"白送"；而新策略下，同样的钱投给高 Uplift 用户，带来了20%的增量。用ROI数据说服他们。

阻力2：运营团队担心影响用户体验

运营担心，如果用户发现"有人收到30元红包，自己只有5元"，会觉得被歧视。

应对方式：设计了"个性化红包"话术，不同用户看到的文案不一样。比如高额红包的文案是"专属福利"，小额红包的文案是"新人礼包"。避免用户直接对比。

阻力3：技术资源不足


初期算法团队人手有限，Uplift 模型上线周期要3个月。业务等不了。

应对方式：先用**简化版策略**快速上线——基于规则筛选出"高活跃+未下单"用户，手动分层发放。虽然不如模型精准，但也能带来一定增量。等模型ready后再切换。

这个过程中，**PM**的价值就是把一个复杂的技术方案，翻译成各方都能理解和接受的语言，推动落地。

传统策略 vs 智能策略：真实效果对比

让我们用一组数据来看看传统分层补贴和 Uplift 智能补贴的实际效果差异：



从上图可以看到，在同样145万的补贴预算下：

- **传统策略：**把大量预算投给了"确定购买者"，增量GMV为258万，ROI = 1.8
- **Uplift策略：**精准投给"可说服者"，增量GMV为465万，ROI = 3.2

ROI提升了80%，这就是 Uplift 模型的真实价值。

效果评估：如何衡量补贴策略的成功？

最后，我们来聊聊如何评估一个补贴策略是否成功。

核心指标：ROI

ROI（投入产出比）是最直接的指标：

$$ROI = \text{增量GMV} / \text{补贴成本}$$

目标应该是：**在同样的补贴预算下，最大化增量GMV。**

上线 Uplift 模型后，ROI从**1.8提升到3.2**，意味着每花1元补贴，能带来3.2元的增量GMV。相比之前提升了近80%。

过程指标：用户分层效果

除了ROI，还需要看**不同 Uplift 分层的实际增量是否符合预期。**

举个例子，做一个"分层验证实验"：

- 把用户按 Uplift 值分成10档（每档10%的用户）
- 在每一档都做AB测试，看实际增量

理想情况下，Uplift 值越高的档位，实际增量也越高。如果出现"倒挂"（比如第3档增量反而比第1档高），说明模型预测有问题，需要重新调参。

长期指标：用户LTV提升

补贴策略不能只看短期增量，还要看**对用户长期价值的影响。**

需要追踪：

- 接受补贴后，用户的30天留存率
- 用户的复购率
- 用户的平均客单价变化

理想情况是：**补贴不只是带来一次性交易，还能帮助用户养成使用习惯，提升LTV。**

比如发现，对于"摇摆用户"，一次合适的补贴能让他们的30天留存率提升15%，复购率提升25%。这说明补贴不只是"烧钱"，而是在"培养用户"。

说点心里话

聊到补贴策略，很多人第一反应是“花钱买效果”，看起来不如推荐算法有技术含量。但真正拆开来，会发现补贴策略的复杂度一点不低——用户分层、因果判断、实验设计、多目标权衡、以及跨团队协作，缺一不可。

更关键的是，补贴是一个**高杠杆策略**：判断对了，能省下大量成本；判断错了，再多预算也很难买到增量。从这个角度看，策略 PM 的核心价值并不在于掌握多少算法细节，而在于：

能否把模糊的业务问题，抽象成可验证的技术问题，再把技术结果真正转化为业务收益。

Uplift 模型只是工具，真正的难点在于——**如何在真实业务约束下，把它用对、用好。**