

推荐PM手把手入门第20讲：大模型时代，LLM正在如何重塑推荐系统？（附淘宝和快手实践拆解）

说实话，当 ChatGPT 火起来那会儿，我内心是有点慌的。


作为一个做了好几年推荐的 PM，我当时就在想：我们这套基于协同过滤、深度学习排序的推荐系统，会不会被大模型直接掀翻重来？我之前积累的那些策略经验，还有用吗？

后来冷静下来仔细观察了一圈，发现现阶段大模型更多是在"补位"——补传统推荐系统的短板。但这只是现在，**长期来看，它可能真的会重构整个推荐范式。**

这一讲，我们先看现在，再聊未来。

一、现状：从"老会计"到"金牌导购"

先说说大模型现在在推荐里扮演什么角色。



我喜欢用两个比喻：

传统推荐系统 = 老会计

- 记性极好，通过统计告诉你："90% 买过 A 的人都买了 B，所以你也买 B 吧"
- 痛点：不懂逻辑。新品？冷门品？没数据它就瞎了
- 强项：主流、高频场景下又快又准

LLM推荐 = 金牌导购

- 会推理："虽然没人买过 A+B，但现在天气降温了，而且快过节了，根据你的风格，这件新上的大衣你一定喜欢"
- 强项：逻辑推理、跨品类联想、理解复杂意图
- 痛点：慢、贵、需要大量算力

所以现阶段的主流玩法是：让两者配合，而不是替代。

老会计继续干他擅长的(高频、主流、有数据)，金牌导购专攻他的强项(长尾、新颖、强意图)。

但这只是过渡期的妥协。

二、实战拆解：两家大厂的不同选择

大模型虽好，但怎么用？淘宝和快手给出了两个截然不同的答案。


2.1 淘宝 RecGPT：稳健派的"外挂大脑"

场景痛点： 淘宝有几十亿商品，每天上下架极快。让大模型把所有商品ID都背下来？不现实。

解决方案： 保留原有推荐系统，把LLM作为一个"超级召回源"插进去。

淘宝 RecGPT: 外挂大脑模式

保留原系统 + LLM作为超级召回源



淘宝RecGPT拆解

具体怎么玩：

1. 用户行为压缩后喂给大模型
2. 大模型推理出"意图标签"(比如"儿童万圣节装备")
3. 拿标签去商品库检索
4. 检索结果再走传统的精排系统

PM视角的关键：

- 这不是推翻重来，是给现有系统装个"懂逻辑的大脑"
- 成本可控：只在需要"理解"的环节用LLM
- 适合大规模、语义信息弱的商品场景

2.2 快手 OneRec：激进派的"原生重塑"

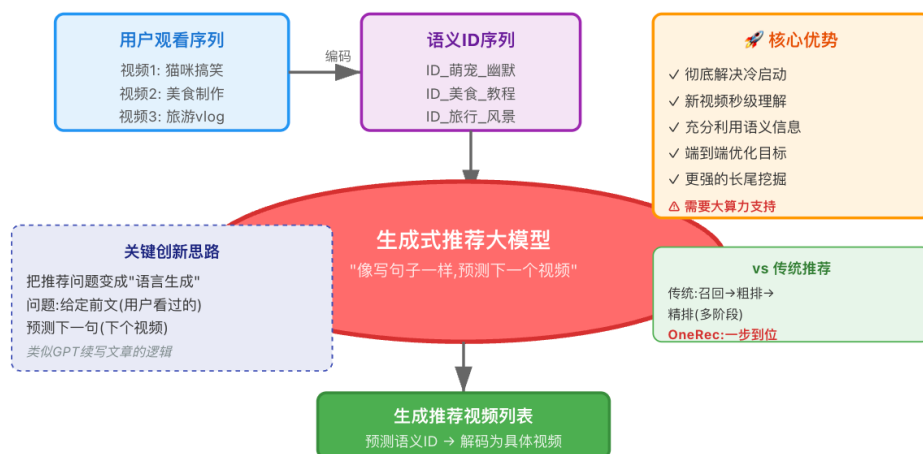
场景痛点：短视频本身就有语义(标题、画面、声音)，冷启动要求极高。

解决方案：端到端生成，试图用一个大模型取代传统的"召回-粗排-精排"漏斗。

快手 OneRec: 原生重塑模式

端到端生成,用一个模型替代传统漏斗

适合: 中等规模内容库 + 语义信息丰富的场景



快手OneRec拆解

具体怎么玩:

1. 给每个视频编一套"语义ID"(类似基因编码)
2. 用户看完猫咪视频后,大模型像写句子一样预测"下一句应该看做饭"
3. 直接生成推荐列表

PM视角的关键:

- 利用了视频天然的语义优势
- 彻底解决冷启动: 新视频只要内容好,大模型立马能读懂
- 需要大算力支持,只能切部分流量实验

思考点:

为什么淘宝选稳健,快手选激进?


因为业务场景根本不同:

- 电商 = 海量SKU + 弱语义 → 外挂模式更合理
- 内容 = 中等规模 + 强语义 → 端到端有想象空间

没有最好的技术,只有最适合的技术。这就是策略PM存在的意义——定方向。

三、PM的工作颗粒度变了什么？

看完大厂操作，落地到我们自己的日常工作中，具体有什么变化？



大模型时代PM工作变化

3.1 从定义"规则"到设计"人设"

以前：你跟算法说"给女装类目加个价格过滤"。

现在：你得像个导演一样设计Agent。

举个例子，在淘宝RecGPT里，你需要定义：

- 我们需要一个"时尚专家"还是"省钱专家"？
- 推荐大衣时，是强调"今年流行的廓形设计"还是"比同类便宜30%"？

这背后是Prompt工程的活儿，但本质是**PM对业务场景的深度理解**。你理解得越深，模型推理得越准。

3.2 从看"数据"到定"标准"

以前：CTR涨了就行。

现在：大模型生成的推荐理由好不好？有没有幻觉？CTR可能还没反应过来。

你需要建立一套"人类评估标准":

- 理由是否有逻辑? (不能循环论证)
- 理由是否个性化? (不能是万金油话术)
- 理由是否真实? (不能编造用户没说过的话)

然后用另一个LLM作为"裁判", 给每条推荐打分。**你的审美上限, 就是模型的上限。**

3.3 时刻算这笔"昂贵"的账

有一说一, 大模型推理真的很贵。

淘宝只敢切1%流量实验, 快手也要做语义压缩。作为PM, 你得天天算账: **为了提升1%的新颖度, 值得多烧50%的GPU吗?**

你可能会设计分层策略:

- 头部用户(高价值): 全量用LLM
- 腰部用户: LLM只负责召回
- 尾部用户: 完全不用, 成本扛不住

或者按场景切:

- 首页信息流: 量太大, 不用LLM
- 搜索结果页: 意图明确, 部分用LLM
- 个性化推荐页: 差异化体验, 全量用LLM


PM需要懂基本的算力成本, 能算清ROI。这在以前是算法的活儿, 现在你也得懂。

四、长期来看: 范式可能真的会变

说了这么多现状, 我想聊聊我对未来的一些思考。

大模型对推荐系统的长期影响

从"补位"到可能的"范式重构"



大模型对推荐系统的长期影响

现在大模型更多是"补位", 但我觉得这只是因为:

1. **算力还不够便宜** - 全量LLM推理成本太高
2. **模型还不够快** - 推理延迟对用户体验有影响
3. **工程还不够成熟** - 端到端方案的稳定性还在验证

但这些都是工程问题, 不是本质问题。

我们看看几个可能的趋势:

趋势1: 从"推荐"到"对话"

现在的推荐本质是单向的: 系统猜你喜欢什么, 塞给你。

但有了LLM, 推荐可以变成双向对话:

- 用户: "我想买个生日礼物送给爱打篮球的朋友"
- 系统理解意图, 追问: "预算多少? 是男生还是女生? 更想要实用的还是有纪念意义的?"
- 基于对话推荐, 并解释理由

这种体验，传统推荐系统做不到。

趋势2：从"点击预估"到"价值预估"

传统推荐优化的是CTR、停留时长这些行为指标。

但LLM可以理解更深层的东西：

- 这个推荐对用户有没有长期价值？
- 会不会让用户审美疲劳？
- 是不是在消费用户的信任？

举个例子，推荐10个擦边内容，短期CTR很高，但长期用户会流失。传统模型很难平衡这个，因为它不理解"价值"这个抽象概念。

LLM有可能让推荐系统从"流量游戏"变成"价值游戏"。

趋势3：从"中心化分发"到"去中心化共创"

现在的推荐是平台说了算：我的算法觉得你该看啥，你就看啥。

但有了LLM，可能会出现：

- 用户自己训练一个"个人推荐Agent"
- 这个Agent了解你的真实偏好，帮你过滤内容
- 平台只提供内容池，分发权交给用户的Agent

这听起来很科幻，但技术上已经可行了。只是商业模式还需要重构。

当然，这些都是我的一些猜想。实际会怎么演进，谁也不知道。

但有一点我很确定：**大模型不会让推荐PM失业，但会让不思考、不学习的PM失业。**

技术永远在变，但PM的核心能力不变：

- 理解业务本质
- 平衡各方利益
- 把技术和场景缝合得天衣无缝

只要你能做到这些，不管是深度学习时代还是大模型时代，你都有价值。